# Náhodné veličiny

- **Náhodná veličina** $X$ na diskrétním pstním prostoru $(\Omega, \Pr)$ je zobrazení $X : \Omega \to \mathbb{R}$.
- Pro náhodnou veličinu $X$ a hodnotu $a \in \mathbb{R}$ definujeme jev $X = a$ jako $\{\omega \in \Omega \mid X(\omega) = a\}$.
- **Střední hodnota** náhodné veličiny $X$ je

$$\mathbb{E}[X] \coloneqq \sum_{\omega \in \Omega} X(\omega) \Pr[\{\omega\}] = \sum_{a \in \mathrm{Rng}(X)} a \cdot \Pr[X = a],$$

  kde $\mathrm{Rng}(X)$ značí obor hodnot (anglicky *range*) zobrazení $X$.

**Věta** (Linearita střední hodnoty)**.** $\mathbb{E}[\alpha_1 X_1 + \cdots + \alpha_n X_n] = \alpha_1 \mathbb{E}[X_1] + \cdots + \alpha_n \mathbb{E}[X_n]$.

**Příklad 1** (Hazard se ne/vyplácí)**.** Nové kasino nabízí hazardní hru se dvěma férovými šestistěnnými kostkami: Nejprve si zvolíte přirozené číslo $n$. Následně zaplatíte jeden žeton a hodíte kostkami. Padne-li na kostkách součet hodnot $n$, tak vyhráváte $n$ žetonů. V opačném případě nedostanete nic.

- Rozmyslete si, v jakém pravděpodobnostním prostoru se hra odehrává.
- Navrhněte náhodnou veličinu, která bude odpovídat počtu získaných žetonů pro dané $n$.
- Rozhodněte, pro které hodnoty $n$ se vám tato hra vyplatí.

*Řešení.* Elementární jevy jsou zobrazení $[2] \to [6]$, nebo ekvivalentně dvojice $(a, b)$ kde $a, b \in [6]$. Zavedeme náhodné veličiny $A, B$ jejichž hodnota je výsledek na první resp. druhé kostce. Naše náhodná veličina pro dané $n$ bude

$$X_n = \begin{cases} A + B, & \text{pokud } A + B = n, \\ 0, & \text{jinak.} \end{cases}$$

Její střední hodnota je $\mathbb{E}[X_n] = n \cdot \Pr[A + B = n]$. Je snadné ověřit, že $\Pr[A + B] = 6 - |n - 7|$, takže se to vyplatí pouze pro $n = 7$, pro které dostaneme $\mathbb{E}[X_7] = 7 \cdot \frac{6}{36} = \frac{42}{36}$ a $n = 8$ pro které to je $\mathbb{E}[X_8] = 8 \cdot \frac{5}{36} = \frac{40}{36}$. Pro $n = 9$ to je na hraně, protože $\mathbb{E}[X_9] = 9 \cdot \frac{4}{36} = 1$, a pro $n = 6$ se to nevyplatí, protože $\mathbb{E}[X_6] = 6 \cdot \frac{5}{36} = \frac{30}{36}$.

**Příklad 2** (Základní rozdělení)**.** Pro náhodnou veličinu $X$ z následujících pstních rozdělení spočítejte pravděpodobnosti jednotlivých hodnot $X$ a určete $\mathbb{E}[X]$.

(a) **Bernoulliho:** Hodíme mincí, kde s pravděpodobností $p$ padne orel. $X$ je 1 pokud padne orel, jinak je 0.

(b) **Binomické:** $X$ je součet $n$ náhodných nezávislých veličin s Bernoulliho rozdělením. To odpovídá tomu, že tou mincí hodíme $n$-krát a sečteme výsledky.

(c) **Geometrické:** $X$ je počet Bernoulliho pokusů, dokud nedostaneme 1. Tedy házíme mincí dokud nám nepadne orel.

*Řešení.* Označme pro náhodnou veličinu $X$ a hodnotu $a$ pravděpodobnost $p_X(a) \coloneqq \Pr[X = a]$.

(a) $p_X(1) = p, \quad p_X(0) = 1 - p, \quad \mathbb{E}[X] = p \cdot 1 + (1 - p) \cdot 0 = p.$

(b) $p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}$ pro dané $k \in \{0, 1, \ldots, n\}$. Pro výpočet střední hodnoty využijeme, že $X$ je součet $n$ Bernoulliho veličin $X_i$, takže z linearity střední hodnoty máme

$$\mathbb{E}[X] = \mathbb{E}[X_1] + \cdots + \mathbb{E}[X_n] = p + \cdots + p = np.$$

(c) $p_X(k) = p \cdot (1-p)^{k-1}$, protože nejprve máme $p-1$ neúspěchů a nakonec jeden úspěch. Určit střední hodnotu není tak přímočaré. Uvedu tři různé triky, co se dají použít.

**První řešení.** Střední hodnota je z definice

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k \cdot p(1-p)^{k-1} = p \sum_{k=0}^{\infty} k(1-p)^{k-1}.$$

Ovšem není zřejmé, jak tohle sečíst. Vzpomeňte si, že pro $0 \leq q < 1$ platí $\sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$. Zkusme to zderivovat podle proměnné $q$. Máme $\sum_{k=0}^{\infty} k \cdot q^{k-1} = \frac{1}{(1-q)^2}$, protože $\frac{d}{dq} q^k = k \cdot q^{k-1}$. Takže $\mathbb{E}[X] = \frac{p}{(1-(1-p))^2} = \frac{1}{p}$, kde jsme použili $q = 1-p$.

**Druhé řešení.** Označme $B$ jev, že první pokus uspěl. Pak $X = 1$. Pokud první pokus selže, tedy nastane opačný jev $\overline{B}$, potom začínáme od znovu a $X = 1 + \text{něco}$. Chápejme výraz $\mathbb{E}[X \mid B]$ intuitivně jako střední hodnotu $X$ za podmínky, že nastal je $B$. Pak

$$\mathbb{E}[X] = \Pr[B] \cdot \mathbb{E}[X \mid B] + \Pr[\overline{B}] \cdot \mathbb{E}[X \mid \overline{B}] = p \cdot 1 + (1-p) \cdot (1 + \mathbb{E}[X]).$$

Důvod proč $\mathbb{E}[X \mid \overline{B}] = 1 + \mathbb{E}[X]$ je, že geometrické rozdělení „nemá paměť.“ Výsledky předchozích pokusů nám neříkají nic o výsledcích budoucích pokusů. Potom

$$\mathbb{E}[X] = p + (1-p) + (1-p)\mathbb{E}[X] = 1 + \mathbb{E}[X] - p\mathbb{E}[X] \implies p\mathbb{E}[X] = 1 \implies \mathbb{E}[X] = \frac{1}{p}.$$

Formálně definujeme střední hodnotu $X$ za podmínky, že nastal je $B$ jako

$$\mathbb{E}[X \mid B] = \sum_{a \in \mathrm{Rng}(X)} a \cdot \Pr[X = a \mid B].$$

Potom z věty o úplné pravděpodobnost $\Pr[A] = \Pr[B]\Pr[A|B] + \Pr[\overline{B}]\Pr[A|\overline{B}]$ platí

$$\begin{aligned}
\mathbb{E}[X] &= \sum_a a \cdot \Pr[X = a] = \sum_a a \cdot \big(\Pr[B]\Pr[X = a \mid B] + \Pr[\overline{B}]\Pr[X = a \mid \overline{B}]\big) = \\
&= \sum_a a \cdot \Pr[B]\Pr[X = a \mid B] + \sum_a a \cdot \Pr[\overline{B}]\Pr[X = a \mid \overline{B}] = \\
&= \Pr[B] \sum_a a \cdot \Pr[X = a \mid B] + \Pr[\overline{B}] \sum_a a \cdot \Pr[X = a \mid \overline{B}] = \\
&= \Pr[B] \cdot \mathbb{E}[X \mid B] + \Pr[\overline{B}] \cdot \mathbb{E}[X \mid \overline{B}].
\end{aligned}$$

**Třetí řešení.** Ukážeme, že pokud náhodná veličina $X$ nabývá pouze hodnot $k \in \mathbb{N}$, potom

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} \Pr[X > k].$$

To platí, protože $\mathbb{E}[X] = \sum_{k=0}^{\infty} k \cdot \Pr[X = k]$ lze rozepsat jako

$$\begin{aligned}
\mathbb{E}[X] &= 1\Pr[X=1] + 2\Pr[X=2] + 3\Pr[X=3] + 4\Pr[X=4] + 5\Pr[X=5] + \cdots \\
&= \Pr[X=1] + \Pr[X=2] + \Pr[X=3] + \Pr[X=4] + \Pr[X=5] + \cdots \\
&\qquad + \Pr[X=2] + \Pr[X=3] + \Pr[X=4] + \Pr[X=5] + \cdots \\
&\qquad\quad + \Pr[X=3] + \Pr[X=4] + \Pr[X=5] + \cdots \\
&\qquad\qquad + \Pr[X=4] + \Pr[X=5] + \cdots \\
&\qquad\qquad\quad \ddots \\
&= \Pr[X>0] + \Pr[X>1] + \Pr[X>2] + \Pr[X>3] + \Pr[X>4] + \cdots .
\end{aligned}$$

Pro naší náhodnou veličinu $X$ z geometrického rozdělení platí $\Pr[X > k] = (1-p)^k$ (prvních $k$ pokusů musí selhat), takže $\mathbb{E}[X] = \sum_{k=0}^{\infty}(1-p)^k = \frac{1}{1-(1-p)} = \frac{1}{p}$.

*Poznámka:* Výsledku, že střední hodnota geometricky rozdělené náhodné veličiny je $\frac{1}{p}$ se přezdívá *lemma o džbánu*. Pokud každý den chodíme se džbánem pro vodu a pravděpodobnost, že se ucho utrhne je $1/n$, potom v průměru bude trvat $n$ cest ke studně, než se ucho uhne. Tento příklad je trochu nepřesný v tom, že chozením se džbánem pro vodu se daný džbán opotřebovává, tedy na rozdíl od geometrického rozdělení „má paměť“ (viz druhé řešení).

**Příklad 3** (Zaječí úmysly)**.** Na palouku panáčkuje $n$ zajíců. Najednou se z lesa vynoří $n$ myslivců, každý z nich zamíří na jednoho náhodně vybraného zajíce a zastřelí ho.

(a) Jaká je pravděpodobnost, že alespoň jeden zajíc přežije?

(b) Jaká je střední hodnota počtu přeživších zajíců?

*Řešení.* (a) Elementární jevy tohoto prostoru jsou funkce $[n] \to [n]$. Abychom spočítali pst, že přežije alespoň jeden zajíc, tak místo toho spočítáme pst, že všichni zemřou. To odpovídá bijekcím $[n] \to [n]$. Takže

$$\Pr[\text{přežije alespoň jeden}] = 1 - \frac{n!}{n^n}.$$

Tento výraz jde velmi rychle k 1 jelikož $\frac{n!}{n^n}$ je zhruba $\frac{1}{e^n}$.

(b) Pro výpočet střední hodnoty využijeme indikátorové náhodné veličiny. Nechť $X_i$ je náhodná veličina taková, že $X_i = 1$, pokud $i$-tý zajíc přežije, a $X_i = 0$ jinak. Celkový počet přeživších zajíců je pak $X = \sum_{i=1}^{n} X_i$.

Zajíc přežije právě tehdy, když na něj nevystřelí ani jeden myslivec. Pravděpodobnost, že na něj konkrétní myslivec *nevybere* cíl, je $\left(1 - \frac{1}{n}\right)$. Protože se myslivci rozhodují nezávisle, pravděpodobnost, že si ho nevybere všech $n$ myslivců, je:

$$\mathbb{E}[X_i] = \Pr[X_i = 1] = \left(1 - \frac{1}{n}\right)^n.$$

K tomuto výsledku můžeme alternativně dojít tak, že si uvědomíme, že elementární jevy, kdy $i$-tý zajíc přežije jsou funkce $[n] \to [n] \setminus \{i\}$ a těch je $(n-1)^n$, zatímco všech elementárních jevů je $n^n$.

Díky linearitě střední hodnoty pak můžeme spočítat očekávaný celkový počet přeživších zajíců jako součet středních hodnot jednotlivých indikátorů:

$$\mathbb{E}[X] = \mathbb{E}\Big[\sum_{i=1}^{n} X_i\Big] = \sum_{i=1}^{n} \mathbb{E}[X_i] = n\left(1 - \frac{1}{n}\right)^n.$$

Výraz $\left(1 - \frac{1}{n}\right)^n$ konverguje k $e^{-1}$, takže průměrně přežije přibližně $\frac{n}{e} \approx 0.368n$ zajíců.

**Příklad 4** (Gotta catch 'em all!)**.** V novém Pokémoním setu je $n$ karet. Kolik si jich průměrně musíme koupit, než získáme všechny? Předpokládáme, že všechny karty jsou stejně pravděpodobné.

*Řešení.* Označme $X$ náhodnou veličinu, která udává celkový počet koupených karet potřebných k získání všech $n$ Pokémonů. Tuto veličinu si rozložíme na součet dílčích náhodných veličin:

$$X = X_0 + X_1 + \cdots + X_{n-1},$$

kde $X_i$ je počet koupených karet potřebných k získání v pořadí $(i+1)$-ního *nového* Pokémona od chvíle, kdy jich ve sbírce máme už $i$.

Nyní určíme střední hodnotu každé veličiny $X_i$:

- Pokud už máme $i \geq 0$ různých karet, v setu zbývá $n - i$ druhů, které ještě nemáme.
- Pravděpodobnost $p_i$, že další zakoupená karta bude nová, je $p_i = \frac{n-i}{n}$.
- Doba čekání na první úspěch (zisk nové karty) se řídí geometrickým rozdělením. Střední hodnota je převrácená hodnota pravděpodobnosti úspěchu:

$$\mathbb{E}[X_{i+1}] = \frac{1}{p_i} = \frac{n}{n-i}.$$

Díky linearitě střední hodnoty je celkový očekávaný počet nakoupených karet součtem očekávaných dob čekání:

$$\begin{aligned}\mathbb{E}[X] = \mathbb{E}[X_0] + \mathbb{E}[X_1] + \cdots + \mathbb{E}[X_{n-1}] = \sum_{i=0}^{n-1} \frac{n}{n-i} = \\ = \frac{n}{n} + \frac{n}{n-1} + \cdots + \frac{n}{2} + \frac{n}{1} = n\left(\frac{1}{1} + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n}\right).\end{aligned}$$

Výsledek můžeme zapsat pomocí $n$-tého harmonického čísla $H_n = \sum_{k=1}^{n} \frac{1}{k}$ jako $\mathbb{E}[X] = n \cdot H_n$. Třeba pro $n = 100$ to je přibližně 519. Pro velká $n$ konverguje $H_n$ k hodnotě $\ln n$.

# Markovova nerovnost

**Věta** (Markovova nerovnost)**.** *Pokud je $X$ nezáporná náhodná veličina a $t > 0$, potom*

$$\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}$$

*Řešení.* Tuto větu si dokážeme. Platí

$$\mathbb{E}[X] = \sum_{a \in \mathrm{Rng}(X)} a \cdot \Pr[X = a] \geq \sum_{\substack{a \in \mathrm{Rng}(X) \\ a \geq t}} a \cdot \Pr[X = a] \geq t \sum_{\substack{a \in \mathrm{Rng}(X) \\ a \geq t}} \Pr[X = a] = t \cdot \Pr[X \geq t].$$

**Příklad 5** (Už se nevejdete)**.** Dopravní podnik na jedné autobusové lince spustil počítání cestujících. Spočítal, že při výjezdu z vybrané zastávky se v autobuse vyskytuje průměrně 8 cestujících. Autobus má kapacitu 40 lidí. Co můžeme říci o pravděpodobnosti, že po obsloužení této zastávky bude autobus plný (nebo dokonce přeplněný)?

*Řešení.* Označme průběrný počet cestujících jako $X$. Podle Markovovy nerovnosti

$$\Pr[X \geq 40] \leq \frac{8}{40} = 0.2.$$

**Příklad 6** (Průměrný věk)**.** Na konferenci přišlo 100 matematiků a jejich průměrný věk je $n$. Rozhodněte, zda mohou nastat následující situace:

(a) Více než polovina z nich má méně než $0.5n$ let.

(b) Více než polovina z nich má alespoň $2n$ let.

*Řešení.* První situace nastat může, třeba kdyby bylo 40ti matematikům 80 let a zbylým 60ti pouze 20 let. Potom $n = \frac{40\cdot 80+60\cdot 20}{100} = 44$.

Druhá situace ovšem nastat nemůže. Tohle lze odargumentovat přímo, ale my využijeme Markovovu nerovnost. Uvažme klasický pravděpodobností prostor, jehož elementární jevy jsou jednotliví matematici a definujme náhodnou veličinu $X$, která danému matematikovi přiřadí jeho věk. Tedy $\mathbb{E}[X] = n$ je průměrný věk přítomných matematiků. Podle Markovovy nerovnosti

$$\Pr[X \geq 2\mathbb{E}X] \leq \frac{\mathbb{E}[X]}{2\mathbb{E}[X]} = \frac{1}{2}.$$

Jelikož z definice je

$$\Pr[X \geq 2\mathbb{E}X] = \frac{\#\text{matematiků jejichž věk je alespoň } 2n \text{ let}}{n} \leq \frac{1}{2},$$

tak počet matematiků jejichž věk je alespoň $2n$ let je nejvýše $n/2$, tedy polovina.

# Rozptyl

- **Rozptyl** náhodné veličiny $X$ je $\operatorname{Var}[X] \coloneqq \mathbb{E}\big[(X - \mathbb{E}X)^2\big]$.

**Pozorování.** $\operatorname{Var}[X] \geq 0$ *jelikož náhodná veličina* $(X - \mathbb{E}X)^2$ *je vždy nezáporná.*

**Příklad 7** (Užitečný vzoreček)**.** Dokažte, že platí rovnost $\operatorname{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$.

*Řešení.* Označme $\mu \coloneqq \mathbb{E}X$. Podle linearity střední hodnoty

$$\operatorname{Var}[X] = \mathbb{E}\big[(X-\mu)^2\big] = \mathbb{E}[X^2-2\mu X+\mu^2] = \mathbb{E}[X^2]-2\mu\mathbb{E}[X]+\mu^2 = \mathbb{E}[X^2]-2\mu^2+\mu^2 = \mathbb{E}[X^2]-\mu^2,$$

kde jsme využili, že $\mu = \mathbb{E}X$ je konstanta.

**Příklad 8** (AQ nerovnost)**.** Odvoďte z předchozí úlohy nerovnost mezi aritmetickým a kvadratickým průměrem

$$\frac{x_1 + x_2 + \cdots + x_n}{n} \leq \sqrt{\frac{x_1^2 + x_2^2 + \cdots + x_n^2}{n}}.$$

*Řešení.* Uvažme klasický pravděpodobnostní prostor $\Omega = [n]$ a definujme náhodnou proměnnou $X : \Omega \to \mathbb{R}$ jako $X(i) = x_i$. Jelikož $0 \leq \operatorname{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$ tak $(\mathbb{E}X)^2 \leq \mathbb{E}[X^2]$ a proto $\mathbb{E}[X] \leq \sqrt{\mathbb{E}[X^2]}$. Když ty střední hodnoty rozepíšete, dostanete přesně AQ nerovnost výše.

**Příklad 9** (Rozptyl hodu mincí)**.** Určete rozptyl náhodné veličiny $X$ z Bernoulliho rozdělení s pravděpodobností $p$.

*Řešení.* Podle předchozí úlohy $\operatorname{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$. Z Druhé úlohy víme, že $\mathbb{E}X = p$. Ještě musíme dopočítat $\mathbb{E}[X^2]$. Jelikož $X$ nabývá pouze hodnoty 0 a 1, tak $X^2$ také nabývá pouze hodnoty 0 a 1. Dokonce platí $X^2 = X$, takže $\mathbb{E}[X^2] = \mathbb{E}[X] = p$, tudíž $\operatorname{Var}[X] = p-p^2 = p(1-p)$.

**Příklad 10** (Bude to lineární?)**.** Určete kolik je $\operatorname{Var}[\alpha X]$ za předpokladu, že znáte $\operatorname{Var}[X]$.

*Řešení.* $\operatorname{Var}[\alpha X] = \mathbb{E}[(\alpha X)^2] - (\mathbb{E}[\alpha X])^2 = \alpha^2\mathbb{E}[X^2] - (\alpha\mathbb{E}[X])^2 = \alpha^2 \operatorname{Var}[X]$.

Tedy pokud naší veličinu lineárně přeškálujeme, tak se její rozptyl změní kvadraticky. Tohle odpovídá tomu, že rozptyl je v kvadratických jednotkách původní veličiny. Například pokud $X$ měří nějakou vzdálenost, je v metrech, tak $\operatorname{Var}[X]$ je v metrech čtverečních (podívejte se ještě jednou na definici).